

Практическая работа 2

Эксперименты с PPO

1 Цель работы

В работе сравниваются четыре варианта обучения PPO в среде PandaPickCube с результатом P1. Задача робота: поднять куб и перенести его к цели. Эксперименты выполнены 4 октября 2026 года.

В scale_500 число обновлений уменьшено с 1001 до 500; в box_target_strong вес box_target увеличен с 8 до 40; в qpos_strong вес robot_target_qpos увеличен с 0,3 до 30; в num_envs_2048 число параллельных сред уменьшено с 4096 до 2048. Остальные параметры PPO сохранены. Все четыре обучения завершились без программной ошибки.

До запуска num_envs_2048 была записана гипотеза: тренировочная награда составит не более 95% от P1, успешных эпизодов будет не больше 8 из 10, а время learn() не превысит 80% от P1.

2 Параметры обучения

Для сравнения использована готовая модель my_first_run из P1, без нового обучения baseline. Финальные модели: model_499.pt для scale_500 и model_1000.pt для остальных вариантов. Полный снимок среды P1 не сохранён, исходные веса награды восстановлены по исходникам.

Параметр	Значение
Сети	Actor и critic: 512, 256, 128; ELU; 66 наблюдений; 8 действий
PPO	lr 0,001; adaptive; clip 0,2; 4 эпохи; 8 minibatches; γ 0,97; λ 0,95; entropy 0,01; desired KL 0,01; grad norm 1
Сбор опыта	40 шагов на среду за обновление; resume = false
Среда	ctrl_dt 0,02 c; sim_dt 0,005 c; action_scale 0,04
Исходные веса награды	box_target 8; gripper_box 4; no_floor_collision 0,25; robot_target_qpos 0,3
Запуск	seed среды и runner 1; save_interval 50; cuda:0; Tesla T4
Версии	Python 3.12.3; Torch 2.8.0 + cu128; JAX 0.6.2; MuJoCo/MJX 3.5.0; playground 0.1.0; RSL-RL 5.5.1

3 Оценка и результаты

Каждая модель проверена на 10 одинаковых сценах с reset seed 42–51. Действия детерминированные, без шума и подмены позиции куба. Эпизод длится до 150 шагов по 0,02 с. Успех: конечное расстояние от куба до цели меньше 0,05 м. Подъём: максимальная высота куба больше 0,2 м. Первый критерий не требует отпускания куба, второй только косвенно показывает захват.

Train reward взят из последней записи Train/mean_reward. Eval return рассчитан с одинаковыми исходными весами награды; SD означает выборочное стандартное отклонение. Из-за изменённых весов Train reward нельзя напрямую сравнивать между всеми вариантами.

Среднее конечное расстояние составило 0,01213 м у P1 и около 0,36796 м у новых моделей. У всех четырёх новых вариантов максимальная высота куба по десяти эпизодам была около 0,03 м. Повторная оценка P1 дала те же результаты, что и исходная.

Вариант	Среды / обновления	Train reward	learn(), с	Eval return $\pm$ SD	Успех / подъём
P1	4096 / 1001	1380,44	4279	1492,76 $\pm$ 119,88	10/10 / 10/10
scale_500	4096 / 500	691,93	2131,22	699,24 $\pm$ 52,58	0/10 / 0/10
box_target_strong	4096 / 1001	1010,83	4300,42	692,93 $\pm$ 50,40	0/10 / 0/10
qpos_strong	4096 / 1001	4534,82	3766,13	106,88 $\pm$ 3,82	0/10 / 0/10
num_envs_2048	2048 / 1001	690,08	2160,93	698,58 $\pm$ 53,53	0/10 / 0/10

4 Кривые с исходными весами награды

Графики построены по 4491 сохранённой записи TensorBoard, без дополнительного сглаживания и заполнения пропусков нулями. Число завершённых обновлений равно step + 1.

У P1 награда растёт после примерно 300 обновлений. У scale_500 и num_envs_2048 она остаётся около 690. На step 499 у P1 уже 1221,38, а у scale_500 только 691,93. Значит, различие нельзя объяснить одной лишь остановкой на 500 обновлениях.

Промежуточный model_500.pt из P1 после 501 обновления дал 6/10 успехов и 10/10 подъёмов. Это модель из того же обучения P1, а не отдельный запуск scale_500.




Рисунок 1. Награда при исходных весах: весь записанный ход обучения и первые 500 обновлений.

5 Кривые с изменёнными весами

У `box_target_strong` итоговая награда равна 1010,83, у `qpos_strong` равна 4534,82. При этом обе модели дали 0/10 успехов. Высокая тренировочная награда `qpos_strong` сопровождается самым низким Eval return: 106,88. Увеличение награды после изменения её весов не означает улучшения решения задачи.




Рисунок 2. `box_target_strong` слева и `qpos_strong` справа. Шкалы разные, высоты кривых напрямую не сопоставляются.

6 Поведение и выводы

По выбранным кадрам трёх видео на вариант (seed 42–44) P1 поднимает куб, переносит и удерживает возле цели. Отпускание не наблюдалось. `scale_500` и `box_target_strong` подходят к кубу, но остаются низко у поверхности. У `num_envs_2048` запястье наклонено, устойчивого подъёма тоже не видно. `qpos_strong` остаётся близко к исходной поднятой позе. Это может быть связано с наградой за сохранение позы. По отдельным кадрам нельзя оценить плавность и мелкую дрожь.

Все три условия гипотезы для 2048 сред выполнены: Train reward составил 49,9896% от P1, успех: 0/10, время: 50,5009%. При 1001 обновлении число переходов уменьшилось со 164 003 840 до 82 001 920. У `scale_500` было 81 920 000 переходов.

Лучший результат показала P1. Однако на условие выполнено только одно обучение, а `train.py` не фиксирует Torch-инициализацию. Одинаковые оценочные сцены не устраняют случайность обучения. Для уверенного вывода о влиянии параметров нужны повторные запуски и отдельные проверочные сцены.

Время `learn()` включает первую компиляцию, но не создание `runner` и оценку. Нагрузка GPU и кэш не контролировались; время P1 округлено до секунды. В конфигурации `empirical_normalization = true`, но у всех моделей фактически Identity. Torch 2.8.0/cu128 использован вместо рекомендованного 2.6.0/cu124 для совместимости cuDNN.

7 Исходные данные

Таблица: `comparison_table.csv`. Кривые: журналы TensorBoard. Команды и настройки: `P2_commands_and_config_RU.txt` и `train.diff` в архивах запусков. Дополнительные материалы: `P2_analysis_and_commands.zip`, `четыре P2_<имя>_verified.zip`, `P2_baseline_evidence.zip` и `P2_reproduction_sources.zip`.